

Detección de fase cardíaca en ecocardiogramas de murinos (Clasificador de sístole y diástole)

1st Jesús Alejandro Salazar González

Posgrado en Ciencia e Ingeniería de la Computación, UNAM

Sede IIMAS Mérida

Yucatán, México

alejandro.salazar9812@comunidad.unam.mx

Abstract—En este trabajo se presenta la implementación de una red neuronal convolucional (CNN) para la clasificación de fases cardíacas (sístole y diástole) en ecocardiogramas de corazones de ratones de laboratorio, basada en la propuesta en [1]. Los resultados en el conjunto de test final arrojan un AUC de 0.95, lo que demuestra que el modelo tiene una buena capacidad para distinguir entre las fases cardíacas de ratones, por otro lado las métricas de sensibilidad y especificidad revelaron un mayor acierto en la predicción de sístole que de diástole. Entre las áreas de mejora identificadas se incluyen el incremento de datos de entrenamiento, la experimentación con funciones de pérdida alternativas y el aumento del número de épocas de entrenamiento.

Index Terms—Red neuronal convolucional, fases cardíacas, sístole, diástole, visión computacional.

I. INTRODUCCIÓN

Las enfermedades cardiovasculares son responsables de más muertes que el cáncer y las enfermedades pulmonares combinadas. Constituyen la principal causa de mortalidad, representando el 43.8 % de todas las muertes [2]. En los ecocardiogramas, el corazón se examina desde varios ángulos (vistas) para cuantificar la enfermedad.

La enfermedad de Chagas, también conocida como tripanosomiasis americana, es una afección que puede causar problemas graves en el corazón y el sistema digestivo [3].

La identificación de las fases de fin de sístole (ES) y fin de diástole (ED) a partir del ecocardiograma es un paso crucial en la cuantificación del tamaño y la función de las cavidades cardíacas [4]. Estas fases permiten estimar diversas medidas, como la dimensión del ventrículo izquierdo (LV), la fracción de eyección del LV (EF), el volumen sistólico, el grosor de la pared y la deformación longitudinal global [5].

El etiquetado manual de estas fases puede ser un proceso laborioso y, dependiendo de la experiencia del intérprete, puede introducir variabilidad en las mediciones.

Por ello, se propone implementar un algoritmo de visión computacional para automatizar el etiquetado de las fases cardíacas en imágenes obtenidas de un grupo de control de ratones de laboratorio. En particular, se plantea entrenar una red convolucional (CNN) basada en la propuesta en [1], la cuál ha sido capaz de indicar la probabilidad de que un fotograma se encuentre en fase sistólica o diastólica en corazones humanos.

Además, se evaluará el desempeño del modelo mediante el cálculo del área bajo la curva (AUC) de la curva ROC, con la expectativa de obtener un valor superior a 0.75. Asimismo, se busca alcanzar una función de pérdida inferior al 20 %.

II. METODOLOGÍA

Para la implementación de este trabajo, se tuvo acceso a una base de datos que contenía una serie de videos de ecocardiogramas de ratones de laboratorio, utilizados como grupo de control en un estudio de infección experimental con *Trypanosoma cruzi*. Cada video tenía una duración aproximada de un minuto y medio. A partir de esta serie de videos, se extrajeron un total de 4530 fotogramas con dimensiones de 768×576 píxeles, en la figura 1 se puede apreciar ejemplos de fotogramas clasificados como fase diastólica y sistólica.

Como primer acercamiento, este proyecto trabajó con 780 imágenes clasificadas en dos categorías: sístole y diástole. Estas imágenes fueron seleccionadas de los registros obtenidos durante los primeros 15 días del experimento.

Las imágenes se redimensionaron a un tamaño de 144×192 píxeles y se convirtieron a escala de grises, normalizándolas a un rango de 0 a 255. Para la validación cruzada, se emplearon 623 imágenes, divididas en siete pliegues con 89 imágenes por pliegue. Durante esta etapa, se aplicaron transformaciones aleatorias, incluyendo cizalladura, zoom e inversión horizontal, para aumentar la variabilidad de los datos. Las 157 imágenes restantes se utilizaron exclusivamente para el test final, únicamente aplicando el redimensionamiento y la normalización a escala de grises.

La red empleada utiliza tres capas convolucionales con una función de activación sigmoideal y una serie de capas de maxpooling. En este trabajo, se modificó la arquitectura para aceptar entradas de 144×192 píxeles, para concordar con el redimensionamiento hecho durante el procesamiento de los fotogramas. Los detalles completos de la red se presentan en la figura 2.

Asimismo, empleamos la función de pérdida descrita en la ecuación (1), que combina el error cuadrático medio y el error promedio. Según [1], esta combinación introduce una penalización adicional a las equivocaciones del modelo, mejorando su capacidad de generalización. La constante $\beta \geq 0$ determina el grado de penalización, y en este caso se experimentará con valores de 0.1 y 0.2. Posteriormente, se seleccionará el modelo




Fig. 1: Ejemplos de fotogramas de la base de datos.

con mejor desempeño por medio de validación cruzada para luego aplicarlo al conjunto de test final.

$$L(\chi, M) = \text{MSE}(\chi, M) + \beta \text{Mean}(\chi, M) \quad (1)$$

Para verificar el comportamiento de la red, se generó una serie de 200 imágenes sintéticas a las que se les añadió ruido Speckle. Estas imágenes consisten en dos clases de elipses, clasificadas como sístole y diástole según su tamaño, como se muestra en la Figura 3. El algoritmo empleado para generar el ruido en estas imágenes se basa en el método descrito por [6].




Fig. 2: Arquitectura.




Fig. 3: Imágenes sintéticas con ruido Speckle.




Fig. 4: Péridida de pruebas preliminares.




Fig. 5: Matrices de confusión de la red final.

III. RESULTADOS Y DISCUSIÓN

A. Prueba preliminar

En la prueba preliminar, se decidió entrenar el modelo utilizando un valor de $\beta = 0.2$ y un total de 15 épocas. De las 200 imágenes generadas, se emplearon 180 para el entrenamiento y 20 para la validación. En la Figura 4 se observa que el modelo converge durante la sexta época.

Con el modelo entrenado, se generaron las matrices de confusión para los conjuntos de entrenamiento y validación, como se muestra en la Figura 5. Los resultados indican que la red logra identificar correctamente las dos clases de elipses, distinguiendo entre las de mayor y menor tamaño.

B. Elección β

En las Tablas I y II se presentan los resultados obtenidos con los valores de β analizados en este trabajo. Se evaluaron métricas como el área bajo la curva (AUC) de la ROC, la pérdida y la precisión para cada uno de los pliegues. Además, se calculó el promedio y la desviación estándar muestral de cada métrica.

De manera general, se observa que $\beta = 0.1$ muestra un mejor desempeño según los promedios obtenidos en cada métrica. Para seleccionar los pesos óptimos, nos basamos en que, con $\beta = 0.1$, las métricas de pérdida y precisión durante el entrenamiento, así como el AUC en la validación, son superiores en el pliegue 4. Aunque el pliegue 1 presenta un

mejor desempeño en el AUC de entrenamiento y la precisión de validación, se considera estos resultados como anómalos, ya que se alejan significativamente de las medias y desviaciones estándar calculadas. Por estos motivos se elige trabajar con los pesos mostrados por el pliegue 4.

TABLE I: Resultados $\beta = 0.1$

No.	Entrenamiento			Validación		
	AUC	Pérdida	Precisión	AUC	Pérdida	Precisión
1	0.923	0.115	0.838	0.909	0.128	0.935
2	0.889	0.143	0.798	0.937	0.140	0.711
3	0.903	0.131	0.839	0.859	0.160	0.829
4	0.921	0.114	0.857	0.957	0.100	0.852
5	0.907	0.126	0.842	0.929	0.112	0.925
6	0.886	0.143	0.794	0.886	0.147	0.813
7	0.921	0.120	0.835	0.956	0.104	0.854
Media	0.907	0.127	0.829	0.919	0.127	0.846
DSM	0.015	0.012	0.024	0.036	0.023	0.075

TABLE II: Resultados $\beta = 0.2$


No.	Entrenamiento			Validación		
	AUC	Pérdida	Precisión	AUC	Pérdida	Precisión
1	0.926	0.121	0.862	0.921	0.121	0.800
2	0.806	0.201	0.738	0.839	0.187	0.929
3	0.860	0.170	0.782	0.794	0.187	0.688
4	0.634	0.254	0.558	0.707	0.243	0.592
5	0.803	0.205	0.717	0.808	0.202	0.677
6	0.869	0.160	0.792	0.918	0.129	0.762
7	0.761	0.223	0.708	0.875	0.199	0.672
Media	0.808	0.191	0.737	0.837	0.181	0.731
DSM	0.094	0.044	0.095	0.076	0.043	0.110

C. Desempeño de la red


En la red seleccionada para el análisis, se graficó el comportamiento de las métricas de pérdida, AUC y precisión durante el entrenamiento. Estas gráficas, tanto para el conjunto de prueba como para el de validación, se presentan en la figura 6. Se observa que el modelo mejora en todas las métricas a medida que aumenta el número de épocas. Esto sugiere que podrían obtenerse mejores resultados al incrementar el número de épocas, por lo que esta posibilidad no se descarta para futuros experimentos.

D. Predicciones


Para evaluar el desempeño de nuestro clasificador en el conjunto de prueba final, se utilizaron las métricas presentadas en la Tabla III. Los resultados obtenidos son bastante competentes en comparación con los reportados por [4] en su modelo de fase profunda. En dicho trabajo, se alcanzaron una sensibilidad de 0.8 y una precisión de 0.74 para un conjunto de imágenes del dataset CAMUS, mientras que en el dataset CardiacPhase los valores fueron de 0.85 y 0.8, respectivamente.



(a) Pérdida



(b) AUC



(c) Precisión

Fig. 6: Desempeño de la red durante el entrenamiento.

En la Gráfica 7, se observa un área bajo la curva (AUC) de 0.95, lo que indica que nuestra red puede distinguir bien entre nuestras clases a pesar de que nuestra red no está diseñada específicamente para corazones de ratones. Sin embargo, la combinación de una alta sensibilidad y una baja especificidad sugiere que el modelo tiende a predecir con mayor precisión la sístole que la diástole.

TABLE III: Resultados de predicción el conjunto de test final

Métrica	Resultado
Exactitud	0.83
Sensibilidad	0.93
Precisión	0.8
Especificidad	0.69
F1-Score	0.86




Fig. 7: Curva ROC.




Fig. 8: Matrices de confusión de la red final.

IV. CONCLUSIÓN

Se implementa una CNN que clasifica la fase cardíaca (sístole y diástole) basada en la propuesta en [1]. El parámetro β que mejor se ajusta a la base de datos empleada es de 0.1. A partir de las gráficas de precisión, AUC y pérdida, se observa que el modelo empleado tiene una tendencia a converger hacia una solución, incrementar el número de épocas podría mejorar el desempeño de la red. El modelo alcanzó

un AUC de 0.95 en para las imágenes de test final, lo que indica una excelente capacidad para distinguir entre clases. Sin embargo, las métricas de sensibilidad y especificidad revelan que el modelo clasifica con mayor precisión la sístole que la diástole. Entre las potenciales áreas de mejora se sugiere incrementar de datos de fotogramas para el entrenamiento de la red, experimentar con distintas funciones de pérdida (entropía cruzada) y probar con el aumento de número de épocas.

REFERENCES

- [1] M. Farhad, M. M. Masud, and A. Beg, "Deep learning based cardiac phase detection using echocardiography imaging," *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 13087 LNAI, pp. 3–17, 2022. [Online]. Available: https://link.springer.com/chapter/10.1007/978-3-030-95405-5_1
- [2] I. Ghorri, D. Roy, R. John, and K. M. Chalavadi, "Echocardiogram analysis using motion profile modeling," *IEEE transactions on medical imaging*, vol. 39, pp. 1767–1774, 5 2020. [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/31804931/>
- [3] MedlinePlus, "Enfermedad de chagas: Medlineplus en español." [Online]. Available: <https://medlineplus.gov/spanish/chagasdisease.html>
- [4] M. Farhad, M. M. Masud, A. Beg, A. Ahmad, L. Ahmed, and S. Memon, "Cardiac phase detection in echocardiography using convolutional neural networks," *Scientific Reports 2023 13:1*, vol. 13, pp. 1–16, 6 2023. [Online]. Available: <https://www.nature.com/articles/s41598-023-36047-x>
- [5] F. T. Dezaki, Z. Liao, C. Luong, H. Girgis, N. Dhungel, A. H. Abdi, D. Behnami, K. Gin, R. Rohling, P. Abolmaesumi, and T. Tsang, "Cardiac phase detection in echocardiograms with densely gated recurrent neural networks and global extrema loss," *IEEE Transactions on Medical Imaging*, vol. 38, pp. 1821–1832, 8 2019.
- [6] C. Perreault and M. F. Auclair-Fortier, "Speckle simulation based on b-mode echographic image acquisition model," *Canadian Conference on Computer and Robot Vision*, pp. 379–386, 2007.