

Detección de anomalías

Semestre: 2026-I

Tarea: Autocodificadores

Profesor: Dr. José Antonio Neme Castillo

Alumno: Jesús Alejandro Salazar González

Instrucciones:

- De la liga: <https://exoplanetarchive.ipac.caltech.edu/docs/data.html> ir a “*Planetary systems*”. De ahí, bajar los datos.
- De los datos obtenidos en (1), filtrar aquellos que no cuenten con información sobre:
 1. periodo orbital (pl_orbper)
 2. radio planetario (pl_rade)
 3. excentricidad (pl_orbeccen)
 4. temperatura en equilibrio (pl_eqt)
 5. masa estelar (st_mass)
 6. gravedad estelar en superficie (st_logg)
 7. distancia a la estrella (sy_dist)
- .
- Normalizar
- Aplicar:
 1. Isolation Forest (parámetros de su elección)
 2. Local Outlier Factor ($k = 1, 2, 3, 5, 10$)
 3. Autoencoders (ver código anexo), usar MSE
 4. Usar su algoritmo de reducción de dimensionalidad favorito sobre los datos y, en la representación obtenida, codifiquen el nivel de anomalía a partir de los tres algoritmos.




Datos

Después de eliminar filas con valores nulos nos quedo un total de 14037 exoplanetas.

pl_orbper	pl_rade	pl_orbeccen	pl_eqt	st_mass	st_logg	sy_dist
13.286891	1226.40	0.0	714.0	0.970	4.544	832.532
13.286900	2.78	0.0	715.0	0.968	4.545	832.532
13.286891	1226.40	0.0	714.0	0.970	4.544	832.532
13.286891	1226.40	0.0	714.0	0.970	4.544	832.532
13.289920	3.50	0.0	759.0	1.028	4.520	832.532

Datos





Se hace un análisis exploratorio de cada variable con sus histogramas.





En estas 3 variables parece que algunos datos se encuentran muy por encima de su valor promedio, se revisaran con más detalle.

Datos

Se hace un análisis exploratorio de cada variable con sus histogramas.





Se analiza con más detalle los histogramas que nos llamaron la atención





- De manera intuitiva se elige un umbral para cada variable.
- Tal vez el dato más raro es el que se encuentra en el máximo de `pl_orber`, ya que se encuentra muy por encima del resto de datos.

Se analiza con más detalle los histogramas que nos llamaron la atención


- En pl_orbeccen se nota que hay una gran densidad de datos con valores 0 lo cual explica el histograma.
- Sin embargo los demás valores mostrados si aparecen con cierta frecuencia.




Se muestran algunos planetas anómalos detectados con los umbrales propuestos.



- Kepler-1704 b aparecen en 2 de las variables analizadas.
- EPIC 248847494 b también llama mucho la atención al estar muy alejado de los demás datos.




Selección de parámetros




- Se selecciona 100 árboles y 10 vecinos porque aparenta que existe estabilidad alrededor de esos valores.

- Se grafican los parámetros detectados vs el número de anomalías detectadas para cada algoritmo.
- Esto podría indicarnos algún tipo de convergencia.





Autocodificador



- Se emplea autocodificador para detectar las anomalías.
- La arquitectura se esquematiza en la figura de la izquierda.
- Se emplearon funciones de activación $\tanh$ en las capas ocultas.
- Se usa MSE como función de pérdida.
- El espacio latente lo podemos emplear para la representación en dos dimensiones de nuestros datos.
- 80 % de los datos se emplea para entrenamiento y 20% para pruebas.
- 100 épocas y un tamaño de bache de 32.

Autocodificador



- Se nota el decremento del MSE con el pasar de las épocas.
- Al parecer nuestro modelo pudo superar 2 mínimos locales de la función de pérdida.



- Al determinar el error cuadrático medio de cada muestra se nota que algunos datos tienen un valor por encima de 0.05.
- Consideraremos estos como anómalos



Autocodificador

- Se representan los datos mediante el espacio latente del autocodificador y también con PCA.
- Se anotan algunas de las anomalías con MSE más alto.
- Las estructuras de PCA y el espacio latente parecen tener semejanza.
- EPIC 248847494 b aparece nuevamente.




Isolation Forest

- En este caso el valores bajos de scoreIF indican que el dato es más anómalo.
- IF parece bien representado en ambos algoritmos de reducción de dimensionalidad.
- A pesar de no ser entrenado explícitamente con estos pares de coordenadas parece indicar que se fija en las regiones menos densas para seleccionar anomalías.



LOF

- Por otra parte LOF no parece estar bien representados en ambos espacios.
- Debido a que este algoritmo se basa en densidad y al existir muchas dimensiones simplemente no fue posible realizar una buena proyección bidimensional.
- A pesar de esto se detecta nuevamente a EPIC 248847494 b y Kepler 1704b.



Conclusiones

- Los análisis exploratorios nos pueden ayudar a darnos una idea si algún dato se encuentra fuera de lo común.
- Se pueden emplear los autocodificadores para detectar anomalías si nos enfocamos a analizar que tan bien se reconstruyen los datos. Mayores errores podría indicarnos la presencia de un dato extraño.
- Escoger la arquitectura lleva su reto, ya que no parece existir una “receta” que nos indique como armar un modelo. Se recomienda primero revisar en la literatura si existen redes empleadas para el fenómeno que se este analizando y no empezar desde cero.
- Los algoritmos de reducción de dimensionalidad parecen ser muy atractivos para representar datos pero siempre hay que tener en consideración que la salida de estos son una “sombra” de la realidad.